Analisi della produttività nella manifattura: un confronto tra modelli predittivi

Un caso studio sul *Garments Worker Productivity Dataset*

Lorenzo Scetto & Annabella Imperatore

16 luglio 2025

Sommario

Questo progetto di machine learning mira a predire l'efficienza produttiva di una fabbrica tessile utilizzando un dataset reale. Sono stati applicati modelli di regressione supervisionata (Random Forest, XGBoost, SVR), valutati con validazione incrociata e metriche standard.

Indice

1 Introduzione **3**

2 Background teorico **3**
2.1 Metriche di valutazione 3
2.2 Modelli impiegati 4
2.3 Validazione incrociata 4

3 Analisi esplorativa del dataset **5**
3.1 Struttura e tipologia dei dati 5
3.2 Statistiche descrittive 5
3.3 Analisi della variabile target: `actual_productivity` 6
3.4 `targeted_productivity` – Produttività attesa 7
3.5 `smv` – Standard Minute Value 8
3.6 Mese di riferimento (`month`) 9
3.7 `over_time` – Minuti di straordinario 10
3.8 `no_of_workers` – Numero di lavoratori per team e giornata . . 11
3.9 `incentive` – Incentivo finanziario 13
3.10 `team` – Identificativo del team produttivo 14

3.11 `no_of_style_change` – Numero di cambi di stile 15
3.12 Standardizzazione delle variabili 17
3.13 Analisi delle correlazioni lineari 17

4 Modelli e metodologie **18**
4.1 Random Forest Regressor 18
4.2 Modello XGBoost 21
4.3 Modello SVR (Support Vector Regression) 22

5 Conclusioni **24**

1 Introduzione

Nel contesto dell'industria manifatturiera, la capacità di monitorare e prevedere l'efficienza dei processi produttivi rappresenta un elemento cruciale per l'ottimizzazione delle risorse e la riduzione dei costi. In particolare, il settore tessile, caratterizzato da un'elevata intensità di manodopera, beneficia fortemente dall'analisi dei dati operativi allo scopo di individuare fattori che influenzano la produttività delle linee di produzione.

In questo lavoro, analizziamo un dataset reale di una fabbrica tessile per costruire modelli supervisionati di regressione in grado di predire l'efficienza produttiva. I modelli selezionati (Random Forest, XGBoost, SVR) sono valutati con validazione incrociata e metriche standard (MAE, MSE, R^2).

2 Background teorico

L'apprendimento supervisionato è un paradigma del machine learning in cui un modello viene addestrato utilizzando un insieme di dati etichettati, ovvero osservazioni associate a un valore noto della variabile target. L'obiettivo è stimare una funzione predittiva in grado di generalizzare su nuovi dati non osservati.

Nel presente lavoro, il problema affrontato è di tipo **regressivo**, in quanto la variabile target (`actual_productivity`) è continua.

2.1 Metriche di valutazione

Per valutare la bontà dei modelli regressivi si utilizzano comunemente le seguenti metriche:

- **MAE (Mean Absolute Error)**
  Indica la media dei valori assoluti degli errori. Fornisce una misura diretta della deviazione media tra le previsioni e i valori osservati.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|$$

- **RMSE (Root Mean Squared Error)**
  È la radice quadrata della media degli errori quadratici. Penalizza maggiormente gli errori di grande entità.

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

- **R^2 (Coefficiente di Determinazione)**
  Indica la proporzione di varianza della variabile dipendente spiegata dal modello. Valori prossimi a 1 indicano buona capacità predittiva.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

2.2 Modelli impiegati

Random Forest Regressor

Random Forest è un modello basato su un insieme di alberi decisionali. Ogni albero viene costruito su un campione casuale dei dati, e le previsioni finali si ottengono aggregando i risultati individuali (media nel caso della regressione). Il metodo è robusto al rumore e alle variabili irrilevanti.

XGBoost Regressor

XGBoost (Extreme Gradient Boosting) è un algoritmo di boosting che costruisce alberi in sequenza, ottimizzando ciascun nuovo modello per correggere gli errori residui di quelli precedenti. È riconosciuto per l'elevata accuratezza predittiva e l'efficienza computazionale.

Support Vector Regressor (SVR)

SVR è una tecnica derivata dal Support Vector Machine, progettata per problemi di regressione. Il modello cerca di trovare una funzione che si discosti dalla verità osservata di una quantità non superiore a ϵ, penalizzando solo gli errori che superano questa soglia. L'uso di kernel, come quello radiale (RBF), consente di modellare relazioni non lineari anche in spazi ad alta dimensionalità.

2.3 Validazione incrociata

Per ottenere una stima affidabile delle prestazioni dei modelli, è stato adottato l'approccio della **validazione incrociata K-fold**, con $K = 10$. Il dataset viene suddiviso in dieci sottoinsiemi: in ogni iterazione, uno viene utilizzato per la validazione mentre i restanti nove per l'addestramento. Le metriche finali sono calcolate come media delle prestazioni su ciascun fold.

3 Analisi esplorativa del dataset

Il dataset `garments.csv` contiene 1197 osservazioni e 15 variabili, tra cui sia attributi numerici che categorici. Ogni riga rappresenta una giornata di lavoro relativa a un team produttivo attivo su una linea tessile.

3.1 Struttura e tipologia dei dati

Le variabili si suddividono in:

- **4 categoriche**: `date`, `quarter`, `department`, `day`
- **5 numeriche intere**: `team`, `over_time`, `incentive`, `idle_men`, `no_of_style_change`
- **6 numeriche continue**: `targeted_productivity`, `smv`, `wip`, `idle_time`, `no_of_workers`, `actual_productivity`

3.2 Statistiche descrittive

Tabella 1: Statistiche descrittive delle variabili numeriche

Variabile	**Media**	**Dev.Std**	**Min**	**25%**	**Mediana**	**Max**
Team	6.43	3.46	1	3	6	12
Targeted productivity	0.73	0.10	0.07	0.70	0.75	0.80
SMV	15.06	10.94	2.90	3.94	15.26	54.56
WIP	1190.47	1837.46	7	774.50	1039.00	23122
Over time	4567.46	3348.82	0	1440	3960	25920
Incentive	38.21	160.18	0	0	0	3600
Idle time	0.73	12.71	0	0	0	300
Idle men	0.37	3.27	0	0	0	45
Style change	0.15	0.43	0	0	0	2
No. of workers	34.61	22.20	2	9	34	89
Actual productivity	0.74	0.17	0.23	0.65	0.77	1.12

Tabella 2: Valori mancanti per variabile

Variabile	**Valori mancanti**
WIP	506
Tutte le altre	0

Tabella 3: Curtosi e asimmetria delle variabili numeriche

Variabile	**Curtosi**	**Asimmetria**
Team	-1.22	0.01
Targeted productivity	5.61	-2.14
SMV	-0.80	0.41
WIP	101.70	9.74
Over time	0.42	0.67
Incentive	299.03	15.79
Idle time	442.64	20.55
Idle men	102.96	9.86
Style change	8.18	2.94
No. of workers	-1.79	-0.11
Actual productivity	0.33	-0.81

Pulizia preliminare

Sono state rimosse tre colonne:

- `idle_time` e `idle_men`: per presenza di outlier estremi e scarsa variabilità utile
- `wip`: per l'elevato numero di valori mancanti e alta distorsione statistica

3.3 Analisi della variabile target: `actual_productivity`

La variabile `actual_productivity` rappresenta la produttività effettiva di ciascun team in una giornata di lavoro, ed è l'obiettivo della predizione nei modelli implementati.

Trattamento degli outlier

L'analisi statistica descrittiva ha evidenziato valori compresi tra 0.23 e 1.12, con una media pari a circa 0.73. Poiché, per definizione, la produttività non dovrebbe eccedere il 100% del target assegnato (valore 1), sono stati trattati come outlier tutti i valori superiori a 1. Tali osservazioni sono state ricondotte al valore massimo teorico di 1, mediante troncamento superiore.

Distribuzione della variabile

Dopo la correzione, la distribuzione della variabile mostra una forma approssimativamente simmetrica, con una leggera asimmetria negativa. I valori sono distribuiti in modo regolare sull'intervallo $[0.23, 1.00]$.

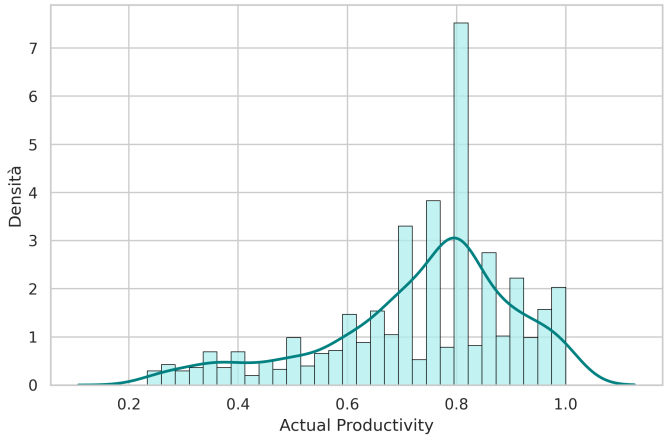

Figura 1: Distribuzione di `actual_productivity`

3.4 `targeted_productivity` – Produttività attesa

La variabile `targeted_productivity` rappresenta la produttività pianificata per ciascun team in una specifica giornata lavorativa. Dopo le operazioni di pulizia, i valori risultano compresi tra 0.35 e 0.80.

Nel corso dell'analisi esplorativa è stato individuato un insieme di osservazioni con valore pari a 0.07, anomalo rispetto alla distribuzione complessiva. Tale valore è apparso incoerente sia dal punto di vista statistico (outlier nella coda sinistra) sia operativo (valore irrealisticamente basso).

Pertanto, si è proceduto alla sostituzione con il valore 0.70, in linea con la mediana e la moda della distribuzione, adottando un criterio di ripristino plausibile fondato su ragioni statistiche e di coerenza contestuale.

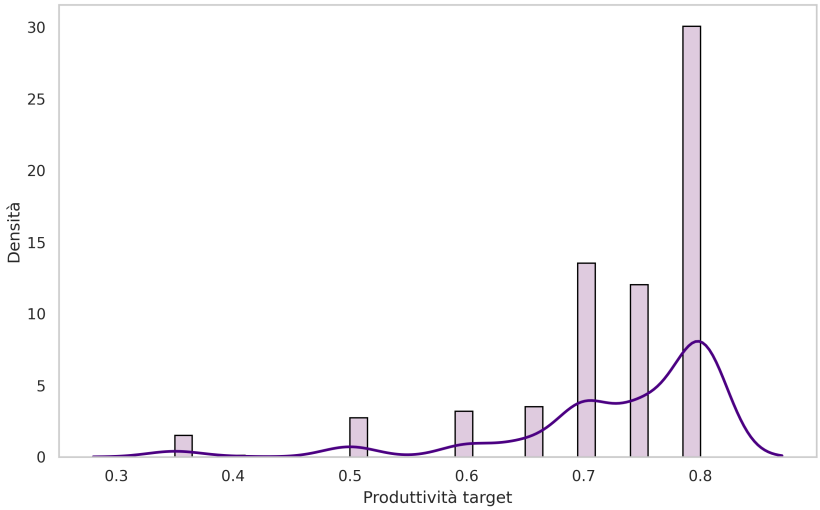

Figura 2: Distribuzione di `targeted_productivity` dopo la correzione

3.5 `smv` – Standard Minute Value

La variabile `smv` rappresenta il tempo standard stimato (in minuti) necessario per completare un'unità di produzione. Tale misura è comunemente utilizzata per quantificare il carico operativo richiesto da ciascuna attività, e si rivela utile per valutare la complessità del processo produttivo.

Distribuzione per classi e densità di frequenza

Per facilitare l'analisi della distribuzione empirica, i valori di `smv` sono stati suddivisi in 8 classi a larghezza disomogenea. A ciascun intervallo è stata associata una densità di frequenza, calcolata come rapporto tra la frequenza assoluta e l'ampiezza del bin, in modo da garantire un confronto corretto tra classi di diversa estensione.

L'istogramma mostra che la maggior parte delle osservazioni si concentra tra i 10 e i 25 minuti. Le code della distribuzione comprendono invece valori superiori ai 40 minuti, interpretabili come operazioni ad alta complessità o maggiore intensità tecnica.

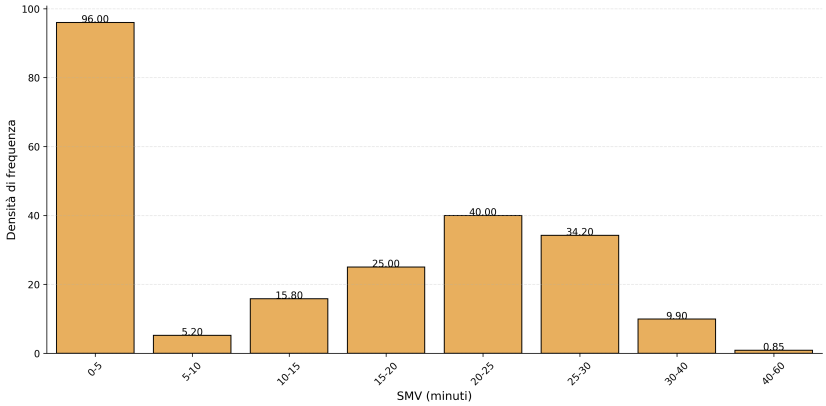

Figura 3: Istogramma delle classi di `smv` con densità di frequenza

3.6 Mese di riferimento (`month`)

A partire dalla variabile `date` è stato estratto il mese di riferimento, con l'obiettivo di analizzare eventuali pattern stagionali nella produttività. Il dataset comprende osservazioni relative ai mesi di **January**, **February** e **March**, distribuite in modo pressoché uniforme.

La Figura 4 mostra la distribuzione della produttività effettiva per ciascun mese, mediante rappresentazione boxplot. Dall'analisi emergono le seguenti osservazioni:

- La mediana della produttività risulta simile tra i tre mesi, con un leggero incremento a gennaio.
- Il mese di febbraio evidenzia una maggiore variabilità interna, con un intervallo interquartile più ampio.
- A gennaio si osserva la presenza di più outlier inferiori, mentre marzo presenta una distribuzione più compatta e centrata.

Tali differenze, sebbene non drastiche, potrebbero riflettere variazioni operative nel carico di lavoro o nella gestione delle linee produttive durante i diversi periodi del trimestre.

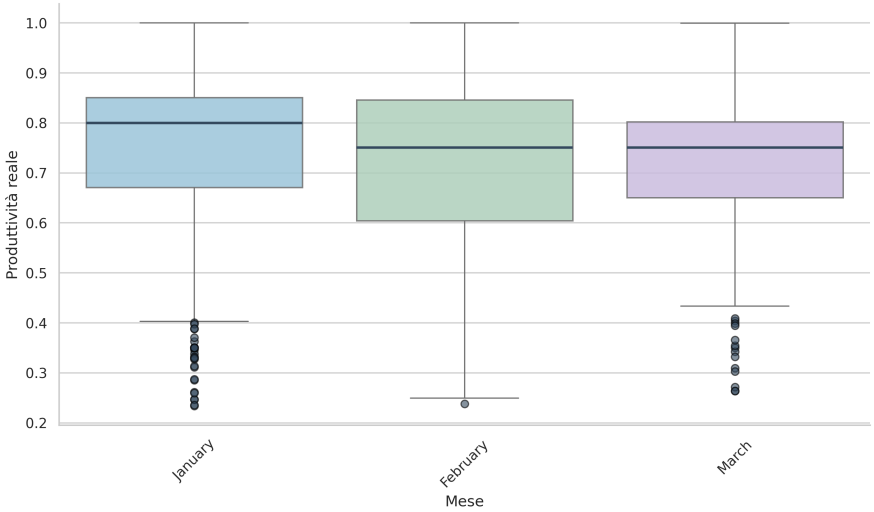

Figura 4: Distribuzione della produttività reale per mese

3.7 `over_time` – Minuti di straordinario

La variabile `over_time` rappresenta il numero complessivo di minuti di straordinario registrati da un team di lavoratori nell'arco di una singola giornata.

Classificazione in intervalli e densità di frequenza

Al fine di analizzare la distribuzione della variabile, `over_time` è stata suddivisa in sette intervalli di ampiezza non uniforme. A ciascun intervallo è stata associata una densità di frequenza, calcolata come rapporto tra la frequenza assoluta e l'ampiezza dell'intervallo. Questo approccio consente di confrontare correttamente classi di larghezza diversa e rilevare con maggiore precisione la concentrazione dei valori osservati.

Analisi dei valori estremi

Dalla distribuzione emerge una forte asimmetria positiva. Il valore del 99° percentile, pari a **10.620 minuti**, è stato utilizzato come soglia per identificare outlier. Le osservazioni superiori a tale soglia sono state analizzate separatamente per evidenziare eventuali anomalie operative.

Tra i casi più rilevanti:

- Il valore massimo osservato è pari a **25.920 minuti**, relativo al team 11 del reparto *sweing*. Tale valore corrisponde, in media, a oltre 18 giornate-uomo di straordinario in un solo giorno.

- Diversi team registrano valori tra 12.000 e 15.000 minuti, frequentemente nel mese di gennaio.

Straordinario per lavoratore

Per valutare l'impatto effettivo dello straordinario, è stata introdotta una nuova metrica: `over_time_per_worker`, ottenuta come:

$$\texttt{over_time_per_worker} = \frac{\texttt{over_time}}{\texttt{no_of_workers}}$$

Questa trasformazione ha permesso di identificare situazioni di particolare intensità, con punte che superano i **630 minuti per lavoratore** (oltre 10 ore), nonostante la correzione di anomalie nel numero di lavoratori (es. casi registrati con 89 operatori).

Distribuzione

Per valutare la forma della distribuzione, è stato costruito un istogramma escludendo il valore massimo di 25.920. Il risultato mostra una forte asimmetria a destra.

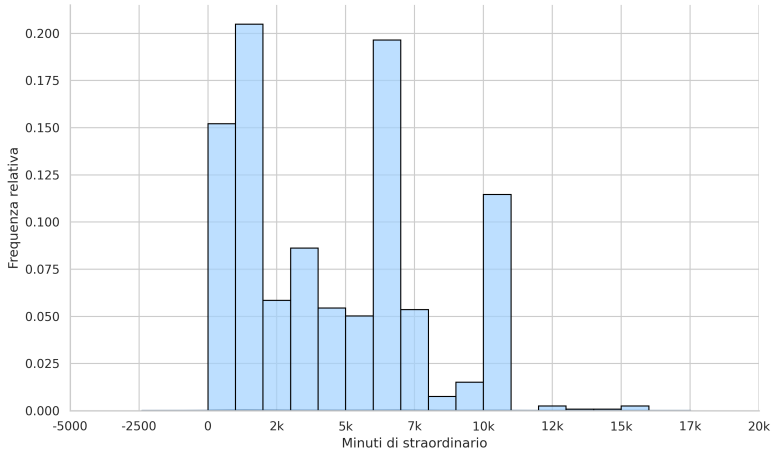

Figura 5: Distribuzione di `over_time` (senza valore massimo)

3.8 `no_of_workers` – Numero di lavoratori per team e giornata

La variabile `no_of_workers` rappresenta il numero totale di lavoratori assegnati a un team in una singola giornata lavorativa. È una variabile numerica discreta con valori compresi tra 2 e 60.

Identificazione e correzione di un outlier

Nel corso dell'analisi è stato individuato un valore anomalo pari a **89 lavoratori**, riferito al team 6 del reparto *sweing*. Tale valore risulta isolato e ampiamente fuori scala rispetto al resto della distribuzione, il cui massimo effettivo è pari a 60.

Si è ritenuto opportuno correggere tale anomalia, sostituendola con il valore **8 lavoratori**, in linea con altri record simili per reparto, team e caratteristiche produttive. La correzione è stata effettuata al fine di evitare distorsioni nelle analisi successive.

Team con 89 lavoratori (prima della correzione)
`department`: sweing
`team`: 6
`targeted_productivity`: 0.80
`over_time`: 5760 minuti
`incentive`: 75
`actual_productivity`: 0.85
`mese`: January

Distribuzione della variabile

La distribuzione della variabile, dopo la correzione, è illustrata nella Figura 6. Si osservano tre picchi principali attorno ai valori 9, 34 e 57, corrispondenti presumibilmente a differenti assetti organizzativi o a vari turni di produzione.

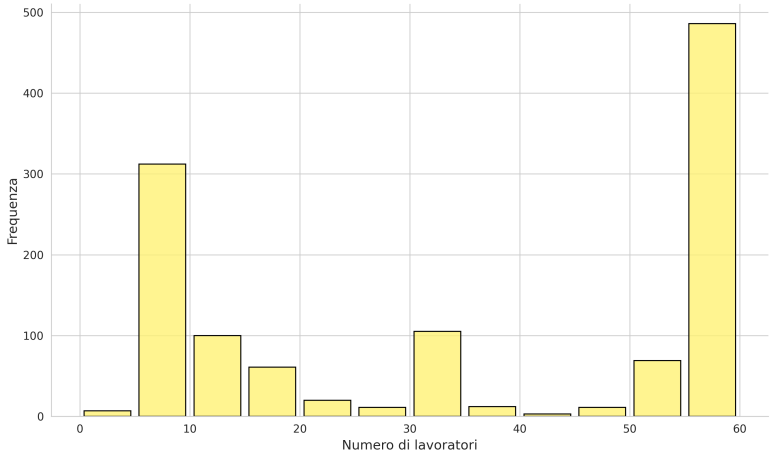

Figura 6: Distribuzione del numero di lavoratori per team

3.9 `incentive` – Incentivo finanziario

La variabile `incentive` rappresenta un incentivo monetario espresso in taka bengalesi (BDT) assegnato a un team. Assume valore `0` in assenza di incentivo e valori interi positivi nei casi in cui sia previsto un riconoscimento economico.

Trasformazione binaria: `has_incentive`

Per facilitare l'analisi e ridurre la dimensionalità, la variabile è stata convertita in una forma binaria (*dummy*), definita come segue:

$$\texttt{has_incentive} = \begin{cases} \texttt{Senza_incentivo} & \text{se } \texttt{incentive} = 0 \\ \texttt{Con_incentivo} & \text{se } \texttt{incentive} > 0 \end{cases}$$

La nuova variabile evidenzia una distribuzione bilanciata tra i due gruppi, su un totale di 1197 osservazioni:

- 604 record (**50,5%**) senza incentivo
- 593 record (**49,5%**) con incentivo

Relazione con la produttività

È stato generato un boxplot per confrontare la produttività effettiva nei due gruppi. I punti rossi indicano la media all'interno di ciascuna categoria.

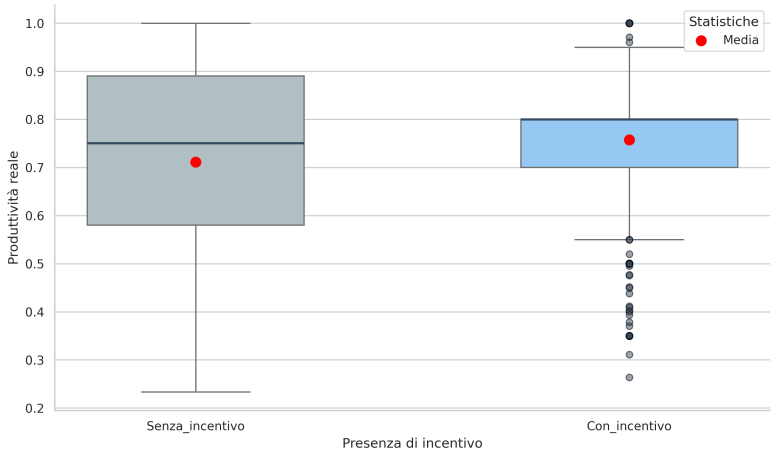

Figura 7: Produttività effettiva in base alla presenza di incentivo

Dall'osservazione grafica emerge una leggera differenza positiva nella produttività media del gruppo con incentivo. Tuttavia, la variabilità interna

rimane elevata per entrambe le categorie. Questa informazione è stata tenuta in considerazione nella fase di modellazione, anche se non è stata effettuata un'analisi inferenziale formale in questa fase.

Eliminazione della variabile originale

Poiché la nuova variabile `has_incentive` cattura integralmente l'informazione rilevante, la variabile numerica originaria `incentive` è stata rimossa dal dataset per evitare ridondanze e semplificare il modello.

3.10 `team` – Identificativo del team produttivo

La variabile `team` è una variabile categorica (rappresentata da etichette numeriche) che identifica univocamente ciascun team attivo nel processo produttivo. Il dataset include 12 team distinti.

Verifica di omogeneità tra i gruppi

Per valutare la presenza di differenze statisticamente significative nella produttività tra i team, sono stati applicati i seguenti test:

$$\begin{aligned} \text{Test di Bartlett:} \quad & K^2(11) = 35{,}524, \quad p = 0{,}0002 \\ \text{Test di Kruskal-Wallis:} \quad & \chi^2(11) = 124{,}220, \quad p = 2{,}56 \times 10^{-21} \end{aligned}$$

Il test di Bartlett ha evidenziato eterogeneità nelle varianze, motivando l'uso del test non parametrico di Kruskal-Wallis. Quest'ultimo ha confermato la presenza di differenze statisticamente significative tra almeno un gruppo rispetto agli altri ($p < 0.001$).

Analisi post-hoc e classificazione dei team

Per identificare in quali coppie di team si osservano differenze significative, è stato eseguito un *test di Dunn* con correzione di Bonferroni. In base ai risultati, i team sono stati raggruppati in tre insiemi statisticamente omogenei, ciascuno caratterizzato da un livello medio di produttività differente:

Tabella 4: Raggruppamento dei team per livello di produttività

Gruppo	Produttività mediana	Team inclusi
Alta	0.800	1, 2, 3, 4, 12
Media	0.751	6, 9, 10
Bassa	0.700	5, 7, 8, 11

Visualizzazione per gruppi omogenei

La seguente rappresentazione boxplot evidenzia la distribuzione della produttività reale per ciascun gruppo identificato. La separazione tra i livelli è coerente con quanto osservato nell'analisi post-hoc, confermando visivamente la presenza di pattern distinti tra i team.

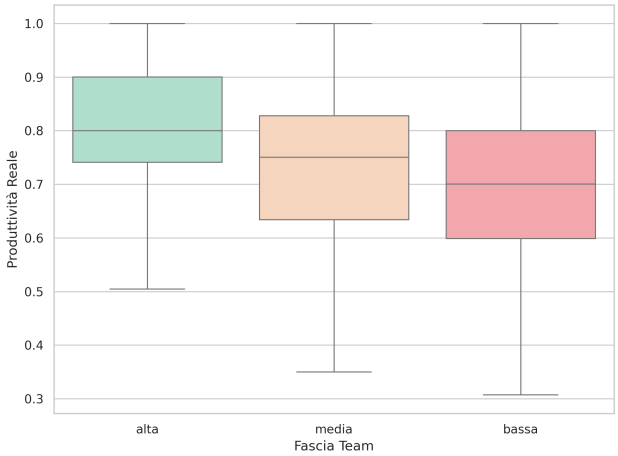

Figura 8: Produttività reale per gruppo omogeneo di team (outlier esclusi)

3.11 `no_of_style_change` – Numero di cambi di stile

La variabile `no_of_style_change` rappresenta il numero di cambi di stile effettuati da un team durante una giornata produttiva. È una variabile categorica ordinale con tre possibili livelli: 0, 1 o 2 cambi.

Analisi della varianza

Un test di Bartlett ha verificato l'omogeneità delle varianze tra i gruppi, restituendo un risultato al limite della significatività:

$$\text{Bartlett: } K^2(2) = 5{,}650, \quad p = 0{,}059$$

L'analisi della varianza a una via (ANOVA) ha evidenziato differenze statisticamente significative tra i gruppi:

$$F(2, 1194) = 35{,}98, \quad p < 0{,}001$$

Test post-hoc: Tukey HSD

Il test di Tukey HSD ha mostrato che:

- I team con **0 cambi** hanno una produttività significativamente più elevata rispetto a quelli con **1** o **2 cambi**.
- Non si osservano differenze significative tra i gruppi con 1 e 2 cambi.

Tabella 5: Risultati del test post-hoc (Tukey HSD)

Confronto	Differenza media	Significativo
0 vs 1	-0.135	✔
0 vs 2	-0.088	✔
1 vs 2	0.047	✗

Raggruppamento binario

Alla luce dei risultati ottenuti, è stata definita una nuova variabile categorica `gruppi_change`, con due livelli:

- `0_cambi`: nessun cambio di stile
- `1_2_cambi`: uno o due cambi di stile

Questa trasformazione ha semplificato l'analisi, preservando l'informazione rilevante. Il boxplot sottostante mostra una chiara differenza di produttività tra i due gruppi:

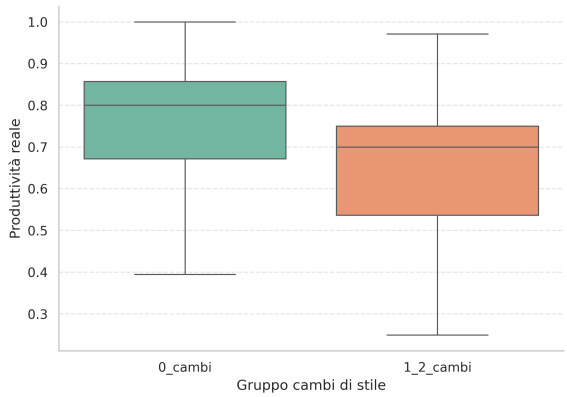

Figura 9: Produttività reale per gruppi di cambi di stile

3.12 Standardizzazione delle variabili

Prima della fase di modellazione, è stata effettuata una standardizzazione delle principali variabili numeriche mediante la trasformazione Z-standard (Z-score). Questa procedura ha consentito di:

- Uniformare la scala delle variabili quantitative, eliminando le differenze di ordine di grandezza;
- Facilitare l'interpretazione della matrice di correlazione;
- Rendere i dati compatibili con algoritmi sensibili alla scala, come il Support Vector Regressor (SVR).

3.13 Analisi delle correlazioni lineari

Per analizzare le relazioni lineari tra le variabili numeriche standardizzate, è stata costruita una matrice di correlazione, visualizzata sotto forma di heatmap (Figura 10).

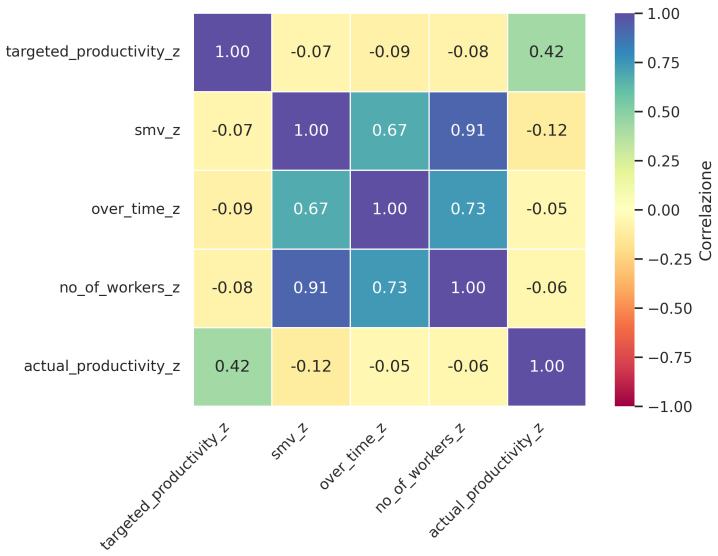

Figura 10: Matrice di correlazione tra variabili standardizzate

Osservazioni

- La variabile target `actual_productivity_z` mostra una correlazione positiva moderata con `targeted_productivity_z` ($r = 0{,}42$).
- Le variabili `smv_z`, `no_of_workers_z` e `over_time_z` risultano fortemente correlate tra loro, in particolare `smv_z` e `no_of_workers_z` ($r = 0{,}91$). Questo evidenzia una marcata interdipendenza tra tempo standard di lavorazione, dimensione del team e straordinario, che potrebbe introdurre fenomeni di multicollinearità nei modelli lineari.
- Le correlazioni tra la variabile target e le variabili `smv_z`, `over_time_z` e `no_of_workers_z` sono molto deboli (prossime allo zero), suggerendo che il loro contributo predittivo potrebbe essere di natura non lineare o dipendere da interazioni con altre variabili.

4 Modelli e metodologie

4.1 Random Forest Regressor

Per modellare la produttività reale standardizzata (`actual_productivity_z`), è stato implementato un modello di regressione Random Forest, scelto per la sua capacità di catturare relazioni non lineari e ridurre il rischio di overfitting tramite l'aggregazione di molteplici alberi decisionali.

Preprocessing

- **Codifica**: Le variabili categoriche (`day`, `has_incentive`, `department`, `fascia_team`, `gruppi_change`, `month`) sono state trasformate mediante One-Hot Encoding.
- **Suddivisione del dataset**: I dati sono stati suddivisi in **training set** (80%) e **test set** (20%) mantenendo una distribuzione bilanciata della variabile target.

Addestramento del modello Il modello è stato addestrato con i seguenti iperparametri, scelti sulla base di esperimenti preliminari:

- `n_estimators = 200`
- `max_features = 3`
- `min_samples_leaf = 10`
- `max_leaf_nodes = 20`

Valutazione iniziale Le prestazioni del modello sul test set sono riportate in Tabella 6:

Tabella 6: Metriche del modello Random Forest (versione completa)

Metrica	Valore
R^2	0.439
RMSE	0.753
MAE	0.434

Importanza delle variabili

L'analisi dell'importanza ha evidenziato che le variabili più rilevanti per la predizione della produttività reale sono:

- `targeted_productivity_z`
- `smv_z`
- `no_of_workers_z`
- `over_time_z`
- `gruppi_change_1_2_cambi`

Strategie di ottimizzazione

Sono state esplorate tre strategie per migliorare le prestazioni predittive del modello:

1. **Modello ridotto**: è stato addestrato un modello utilizzando esclusivamente le variabili più importanti sopra elencate. I risultati, riportati in Tabella 7, mostrano un miglioramento significativo rispetto al modello iniziale.

   Tabella 7: Prestazioni del modello Random Forest ridotto

Metrica	**Valore**
R^2	0.481
RMSE	0.723
MAE	0.510

2. **Rimozione outlier**: è stata condotta un'analisi dei residui sul modello ridotto, individuando 105 osservazioni anomale. Dopo la rimozione, è stato addestrato un nuovo modello sui dati "puliti". Le performance migliorano ulteriormente (Tabella 8):

   Tabella 8: Prestazioni del modello Random Forest sui dati puliti

Metrica	**Valore**
R^2	0.679
RMSE	0.448
MAE	0.324

3. **Cross-validation**: per stimare la robustezza del modello finale, è stata applicata una validazione incrociata 10-fold. I risultati medi sono i seguenti:

Tabella 9: Prestazioni in cross-validation (modello Random Forest pulito)

Metrica	**Media**	**Deviazione Std.**
R^2	0.670	$\pm$ 0.087
RMSE	0.355	$\pm$ 0.036
MAE	0.486	$\pm$ 0.050

4.2 Modello XGBoost

Il modello **XGBoost** (Extreme Gradient Boosting) è stato implementato per stimare la produttività reale standardizzata (`actual_productivity_z`), utilizzando un insieme di predittori numerici e categorici (codificati tramite One-Hot Encoding).

L'addestramento è stato condotto sul dataset pulito (`df_clean`), ottenuto rimuovendo gli outlier residui identificati nella fase di modellazione con Random Forest. I principali iperparametri utilizzati sono i seguenti:

- `n_estimators = 100`
- `max_depth = 4`
- `learning_rate = 0.1`
- `subsample = 0.8`
- `colsample_bytree = 0.8`

Prestazioni del modello I risultati ottenuti sul test set indicano un'elevata capacità predittiva del modello:

Tabella 10: Prestazioni del modello XGBoost

Metrica	Valore
R^2	0.836
RMSE	0.320
MAE	0.223

Validazione incrociata La validazione tramite 10-fold cross-validation ha confermato la buona generalizzabilità del modello, con risultati stabili:

Tabella 11: Risultati cross-validation (10-fold) – XGBoost

Metrica	Media	Dev. Std.
R^2	0.666	$\pm$ 0.106
RMSE	0.315	$\pm$ 0.035
MAE	0.442	$\pm$ 0.049

I risultati suggeriscono una leggera superiorità rispetto al modello Random Forest, sia in termini di capacità predittiva che di stabilità.

Analisi SHAP: interpretabilità del modello

Per comprendere l'impatto delle variabili predittive sul modello, è stata condotta un'analisi di interpretabilità basata sui valori **SHAP** (SHapley Additive exPlanations), che consente di attribuire a ogni predizione un contributo da parte delle singole variabili.

Dall'analisi emerge che le variabili più influenti sono:

- `targeted_productivity_z`
- `smv_z`
- `no_of_workers_z`
- `gruppi_change_1_2_cambi`
- `over_time_z`

L'uso dei valori SHAP ha dunque fornito una lettura trasparente del modello, confermando la rilevanza di variabili già individuate in precedenti analisi di importanza.

4.3 Modello SVR (Support Vector Regression)

Durante l'analisi esplorativa, è emersa una forte collinearità tra alcune variabili predittive standardizzate, potenzialmente problematica per modelli come la **Support Vector Regression (SVR)**, che risultano sensibili alla *multicollinearità*, compromettendone stabilità e capacità di generalizzazione.

Valutazione della multicollinearità: VIF

Al fine di valutare la presenza di multicollinearità tra le variabili esplicative, è stato calcolato il *Variance Inflation Factor* (VIF) limitatamente alle variabili numeriche continue. Tale scelta è giustificata dal fatto che il VIF non è adatto per variabili categoriche binarie o fattoriali, le quali potrebbero distorcere l'interpretazione dei risultati.

- `smv_z` (VIF = 6.27)
- `no_of_workers_z` (VIF = 7.34)

Valori superiori a 5 confermano una forte dipendenza lineare tra queste variabili e le altre predittori, motivando l'adozione di una trasformazione decorrelante.

Riduzione dimensionale: PCA

Per affrontare la multicollinearità e ridurre la dimensionalità, è stata applicata una **Principal Component Analysis (PCA)**. L'obiettivo era mantenere almeno il 95% della varianza complessiva, risultato raggiunto con 6 componenti principali, che spiegano il 97.1% della varianza:

Tabella 12: Varianza spiegata per componente

Componente	Varianza spiegata
PC1	57.2%
PC2	21.5%
PC3	7.8%
PC4	5.8%
PC5	2.7%
PC6	2.5%

Le prime componenti principali sono risultate fortemente influenzate da: `no_of_workers_z`, `smv_z`, `over_time_z` (PC1) e `targeted_productivity_z` (PC2).

Verifica della decorrelazione tra componenti

Per validare l'efficacia della PCA nella riduzione della multicollinearità, è stata calcolata la matrice di correlazione tra le sei componenti principali. Il risultato ha mostrato una struttura perfettamente diagonale, con coefficienti di correlazione pari a 1 sulla diagonale principale e prossimi a 0 altrove, confermando l'assenza di correlazione lineare tra le componenti.

In aggiunta, l'analisi dei loadings ha evidenziato che la prima componente (PC1) sintetizza la combinazione altamente collineare tra `no_of_workers`, `smv` e `over_time`, isolandone l'influenza. Le componenti successive risultano dominate da variabili distinte come `targeted_productivity` (PC2), o da combinazioni più leggere di variabili categoriche.

Questo comportamento conferma che la PCA ha decorrelato efficacemente le predittori, restituendo uno spazio latente più stabile e interpretabile per l'addestramento del modello SVR.

Addestramento del modello SVR su componenti PCA

Il modello SVR è stato addestrato utilizzando le sei componenti principali. Una procedura di tuning iperparametrico tramite `GridSearchCV` ha individuato i seguenti parametri ottimali:

- `C = 10`
- `epsilon = 0.1`
- `gamma = 'scale'`

Prestazioni del modello:

Tabella 13: Metriche di valutazione del modello SVR (dopo PCA)

Metrica	Valore
R^2	0.676
RMSE	0.450
MAE	0.280

Validazione incrociata: Una validazione 10-fold ha confermato la buona generalizzazione del modello:

Tabella 14: Cross-validation del modello SVR (post PCA)

Metrica	Media	Dev. Std.
R^2	0.573	$\pm$ 0.123
RMSE	0.501	$\pm$ 0.048
MAE	0.352	$\pm$ 0.035

Conclusioni

L'applicazione della PCA ha permesso di mitigare efficacemente il problema della multicollinearità, migliorando la coerenza interna delle variabili e la stabilità del modello SVR.

5 Conclusioni

In questo lavoro sono stati sviluppati e confrontati tre modelli di regressione supervisionata per la previsione della produttività reale dei team: **Random Forest**, **XGBoost** e **SVR** con riduzione dimensionale tramite **PCA**.

Il processo ha incluso un'accurata fase di pulizia e trasformazione dei dati, seguita dall'ingegnerizzazione delle variabili, addestramento dei modelli

e validazione tramite suddivisione training/test e cross-validation a 10 fold. Le metriche di valutazione dei modelli sono riportate nella Tabella 15.

Tabella 15: Confronto delle performance su test set

Modello	$\boldsymbol{R^2}$	**RMSE**	**MAE**
Random Forest (con dati puliti)	0.566	0.518	0.379
XGBoost	**0.632**	**0.477**	**0.333**
SVR + PCA	0.396	0.611	0.412

Analisi comparativa

- Il modello **XGBoost** ha evidenziato le migliori prestazioni in tutte le metriche, grazie alla sua capacità di modellare in modo efficace relazioni non lineari e complesse tra le variabili.
- Il modello **Random Forest**, dopo l'eliminazione degli outlier e l'ottimizzazione degli iperparametri, ha mostrato un comportamento stabile e competitivo, confermandosi una soluzione affidabile anche in presenza di dati rumorosi.
- Il modello **SVR** ha beneficiato dell'uso della **PCA**, che ha ridotto la multicollinearità tra le feature e migliorato la stabilità del modello. Tuttavia, le sue performance complessive sono risultate inferiori rispetto agli altri modelli ensemble.

Considerazioni finali L'analisi ha evidenziato il ruolo chiave di variabili come `targeted_productivity`, `smv` e `no_of_workers`, confermato anche dall'analisi di interpretabilità tramite **valori SHAP**, che ha fornito un contributo significativo alla comprensione del funzionamento interno del modello XGBoost.

Nel complesso, il progetto ha dimostrato l'efficacia dell'integrazione tra tecniche statistiche e modelli di machine learning nel contesto della previsione della produttività manifatturiera, offrendo una base solida per sviluppi futuri in ottica di ottimizzazione e supporto decisionale.